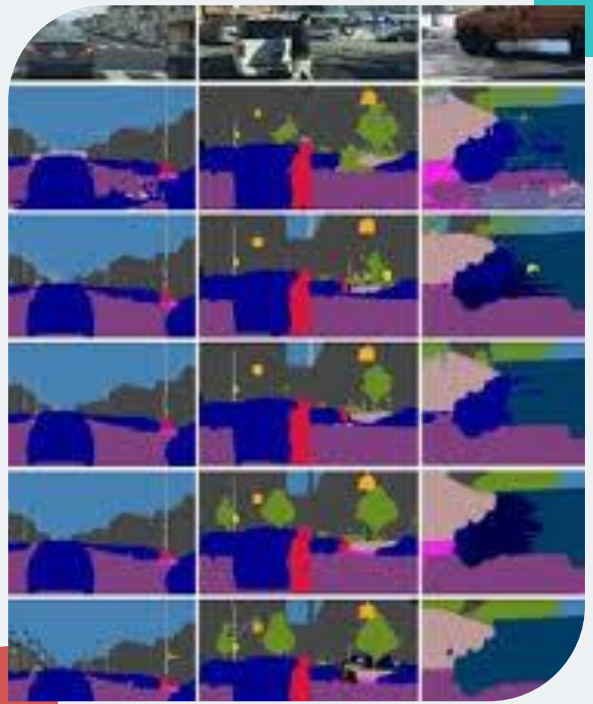
ENSI CAEN
ÉCOLE PUBLIQUE D'INGÉNIEURS
CENTRE DE RECHERCHE

Rapport Quantisation

de Arthur DEFORGE

L'École des Ingénieurs Scientifiques

Modèle et Dataset



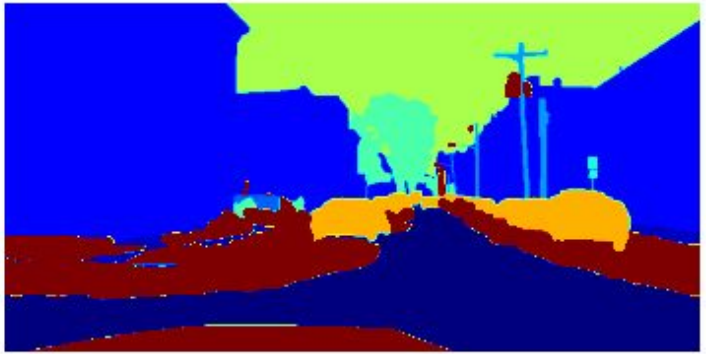
- Modèle : **DeepLabV3+ (Backbone ResNet50)**.
- Données : **BDD100K**
- Taille d'entrée : **768 x 384**
- ***Objectif*** : Adapter un modèle pré-entraîné sur COCO (21 classes) vers le contexte routier BDD100K (19 classes).
- ***Classes cibles*** : Road, Car, Person, Traffic Light, etc..

Protocole de Test : L'Image de Référence

Ref Input: 7d06fefd-f7be05a6.jpg



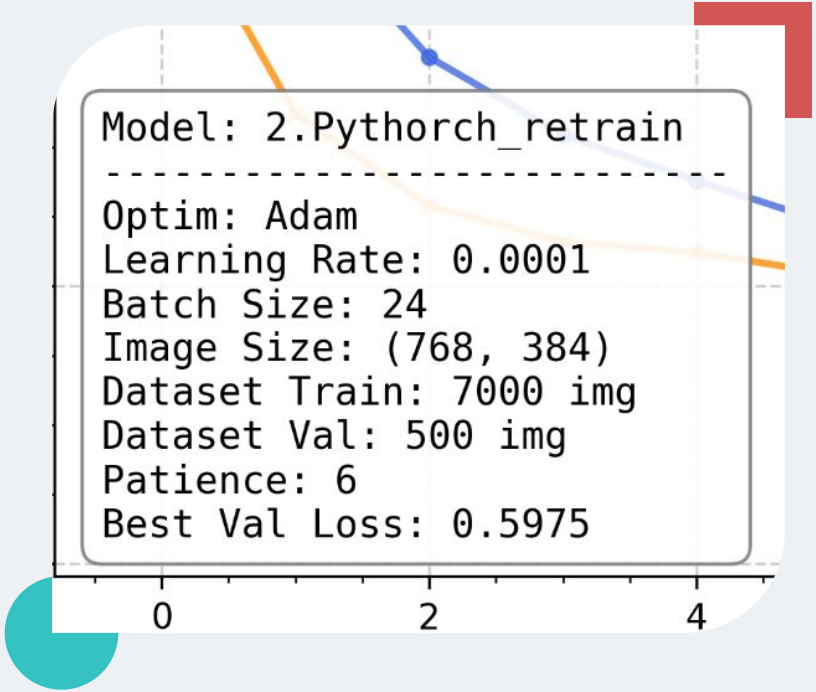
Ref Ground Truth



Cette image servira de fil conducteur tout au long du workflow.

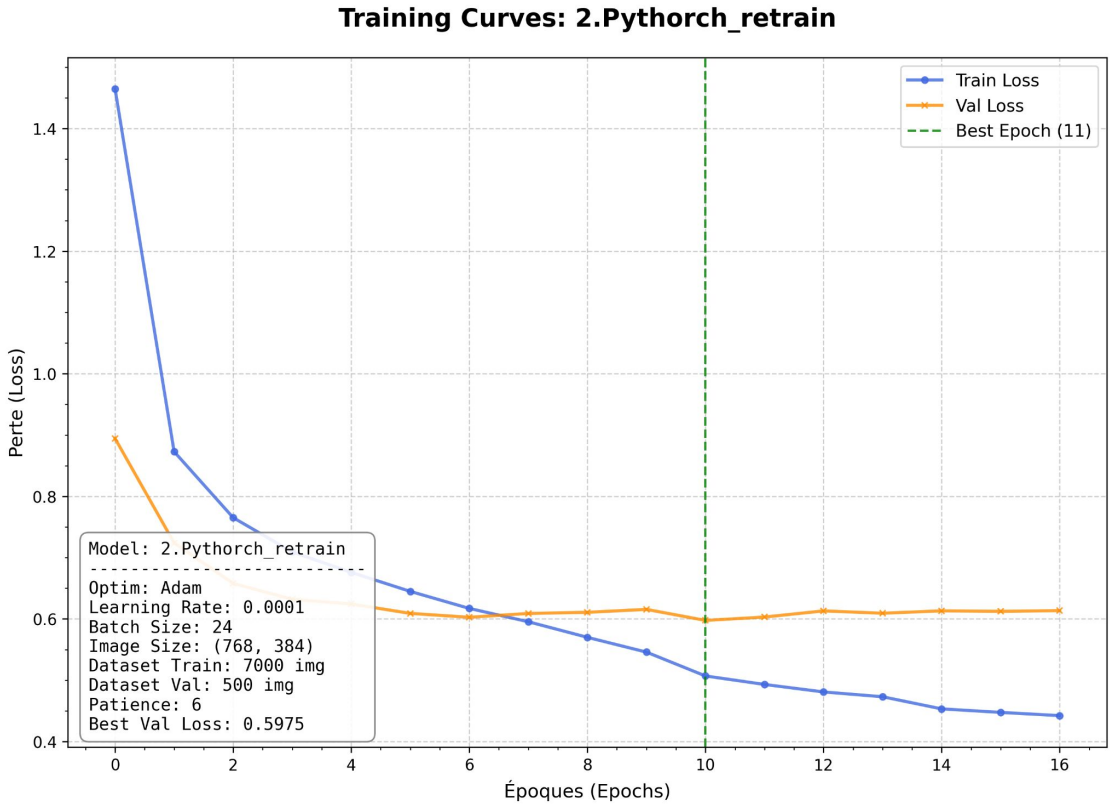
Pourquoi elle ? Scène complexe contenant : Route, Véhicules, Ciel, Végétation et panneaux. Elle permet de juger la finesse de la segmentation.

Configuration du Fine-Tuning



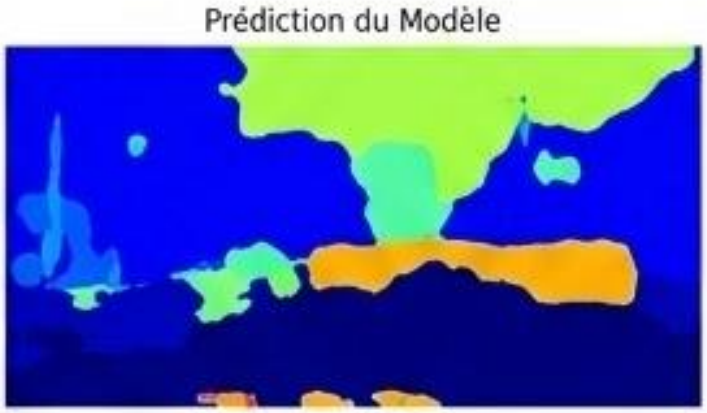
- **Architecture** : Le backbone est figé pour conserver l'extraction de features génériques.
- **Modification** : Remplacement de la dernière couche de classification (21 -> 19 canaux).
- **Hyperparamètres** : Learning Rate, Batch Size (24), Optimizer (Adam/SGD).

Performance de l'Apprentissage (PyTorch)



- Convergence rapide grâce au Transfer Learning.
- Stabilité atteinte après X époques.
- Pas de signe majeur d'overfitting.

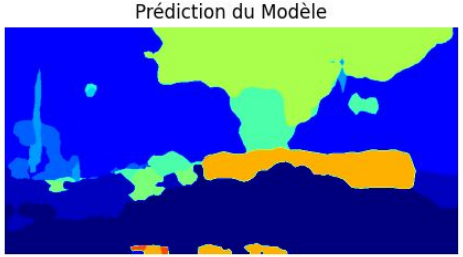
Validation du Modèle PyTorch

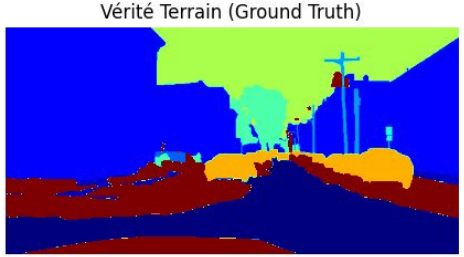


ID	Classe	Score IoU (%)	Performance
0	Road	90.36%	⭐ Excellent
1	Sidewalk	39.44%	Moyen
2	Building	76.30%	Très bon
3	Wall	19.21%	Faible
4	Fence	15.76%	Faible
5	Pole	26.78%	Moyen
6	Traffic Light	26.20%	Moyen
7	Traffic Sign	24.35%	Moyen
8	Vegetation	78.28%	Très bon
9	Terrain	32.14%	Moyen
10	Sky	91.41%	⭐ Excellent
11	Person	58.77%	Bon
12	Rider	0.00%	⚠️ Non détecté
13	Car	83.03%	⭐ Excellent
14	Truck	52.22%	Bon
15	Bus	60.68%	Bon
16	Train	0.00%	⚠️ Non détecté
17	Motorcycle	0.00%	⚠️ Non détecté
18	Bicycle	1.84%	Très faible

Protocole de Test : Validation du Modèle PyTorch









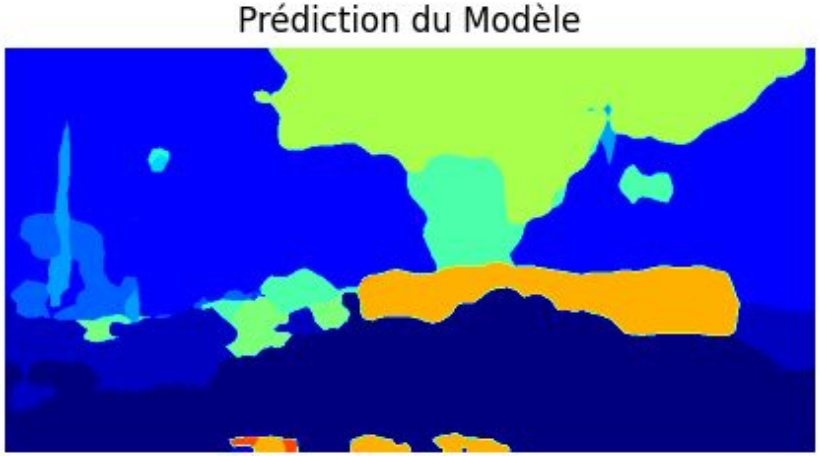
Métrique	Valeur
Modèle	deeplabv3_resnet50_bdd100k_retrain_HR.pth
Global Pixel Accuracy	88.34%
Mean IoU (mIoU)	40.88%

Exportation et Optimisation

PyTorch (.pth) → Export Brut → ONNX Simplifier → Modèle Final (.onnx)

- **Pourquoi** ? Format standard pour l'interopérabilité et le déploiement.
- **Simplification** : Fusion des couches (Conv + BatchNorm) et nettoyage du graphe (Constant Folding) grâce à onnx-simplifier.
- **Résultat** : Structure figée, prête pour l'inférence.

Vérification de la Conversion



- **Résultat visuel :** Strictement identique au modèle PyTorch.
- **Précision :** Les scores mIoU sont inchangés (perte négligeable liée à la précision flottante).
- Le modèle est prêt pour la quantification.

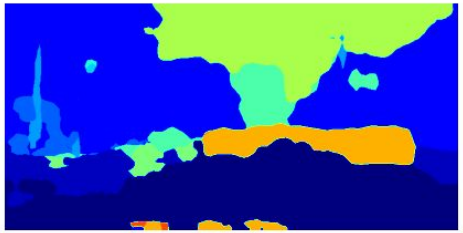
ID	Classe	Score IoU (%)	Performance
0	Road	90.36%	⭐ Excellent
1	Sidewalk	39.44%	Moyen
2	Building	76.30%	Très bon
3	Wall	19.21%	Faible
4	Fence	15.76%	Faible
5	Pole	26.78%	Moyen
6	Traffic Light	26.20%	Moyen
7	Traffic Sign	24.35%	Moyen
8	Vegetation	78.28%	Très bon
9	Terrain	32.14%	Moyen
10	Sky	91.41%	⭐ Excellent
11	Person	58.77%	Bon
12	Rider	0.00%	⚠️ Non détecté
13	Car	83.03%	⭐ Excellent
14	Truck	52.22%	Bon
15	Bus	60.68%	Bon
16	Train	0.00%	⚠️ Non détecté
17	Motorcycle	0.00%	⚠️ Non détecté
18	Bicycle	1.84%	Très faible

Protocole de Test : Vérification de la Conversion

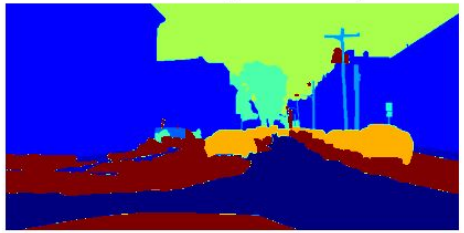
Image : 7d06fefd-f7be05a6.jpg



Prédiction du Modèle



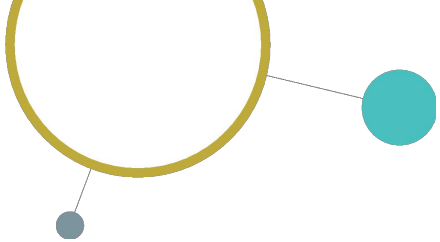
Vérité Terrain (Ground Truth)





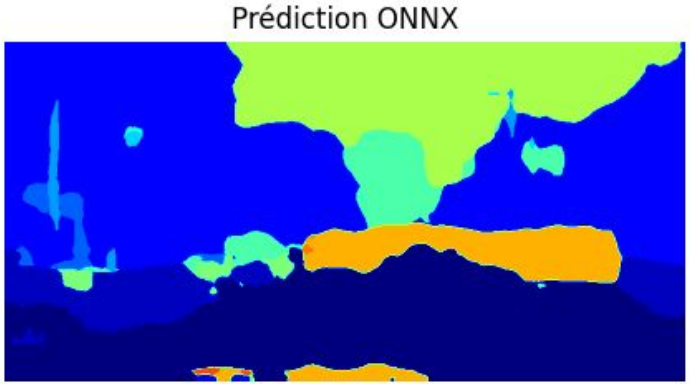
Métrique	Valeur
Modèle	deeplabv3_resnet50_bdd100k_retrain_HR.onnx
Global Pixel Accuracy	88.34%
Mean IoU (mIoU)	40.88%

Quantification Statique (INT8)



- **Méthode :** Post-Training Quantization (Static).
- **Calibration :** Utilisation de 100 images du dataset Train pour calibrer les min/max des tenseurs.
- **Gain :** Réduction de **4x** la taille du modèle.

Impact de la Quantification



- **Analyse :** La perte de précision est minime (< 1%).
- Visuellement, la segmentation reste robuste sur l'image de référence.

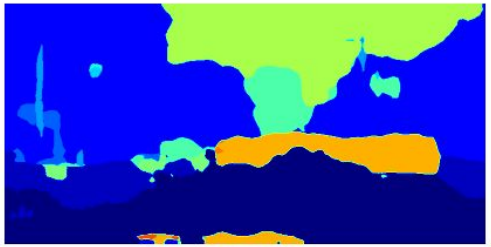
ID	Classe	Score IoU (%)	Variation vs FP32
0	Road	90.18%	-0.18
1	Sidewalk	39.20%	-0.24
2	Building	75.84%	-0.46
3	Wall	17.55%	-1.66
4	Fence	16.40%	+0.64
5	Pole	26.66%	-0.12
6	Traffic Light	25.85%	-0.35
7	Traffic Sign	24.76%	+0.41
8	Vegetation	78.03%	-0.25
9	Terrain	31.18%	-0.96
10	Sky	91.32%	-0.09
11	Person	58.50%	-0.27
12	Rider	0.00%	=
13	Car	83.00%	-0.03
14	Truck	51.85%	-0.37
15	Bus	58.73%	-1.95
16	Train	0.00%	=
17	Motorcycle	0.00%	=
18	Bicycle	3.61%	+1.77

Protocole de Test : Impact de la Quantification

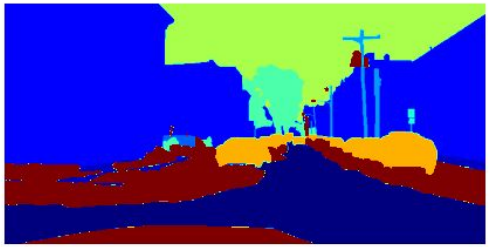
Image : 7d06fefd-f7be05a6.jpg



Prédiction ONNX



Vérité Terrain





Métrique	Valeur
Modèle	deeplabv3_resnet50_bdd100k_retrain_HR_quantized.onnx
Global Pixel Accuracy	88.16%
Mean IoU (mIoU)	40.67%

Conclusion et Benchmark

Étape	Format	Taille (MB)	Précision (mIoU)
1. Entraînement	PyTorch (.pth)	~160.6 MB	~40.88 %
2. Export	ONNX (FP32)	~160.2 MB	~40.88 %
3. Optimisation	ONNX (INT8)	~40.3 MB	~40.67 %

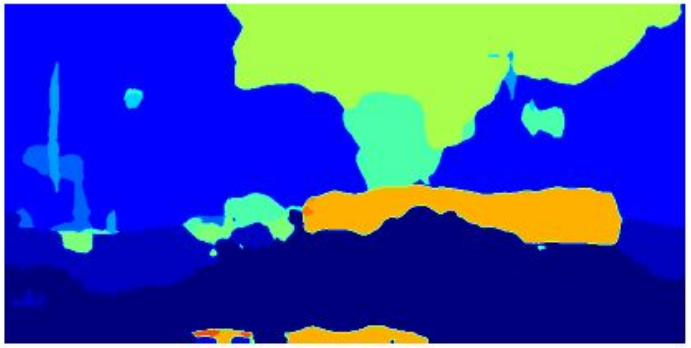
- Le workflow est validé de bout en bout.
- Le modèle est divisé par 4 en taille avec une perte de qualité négligeable.

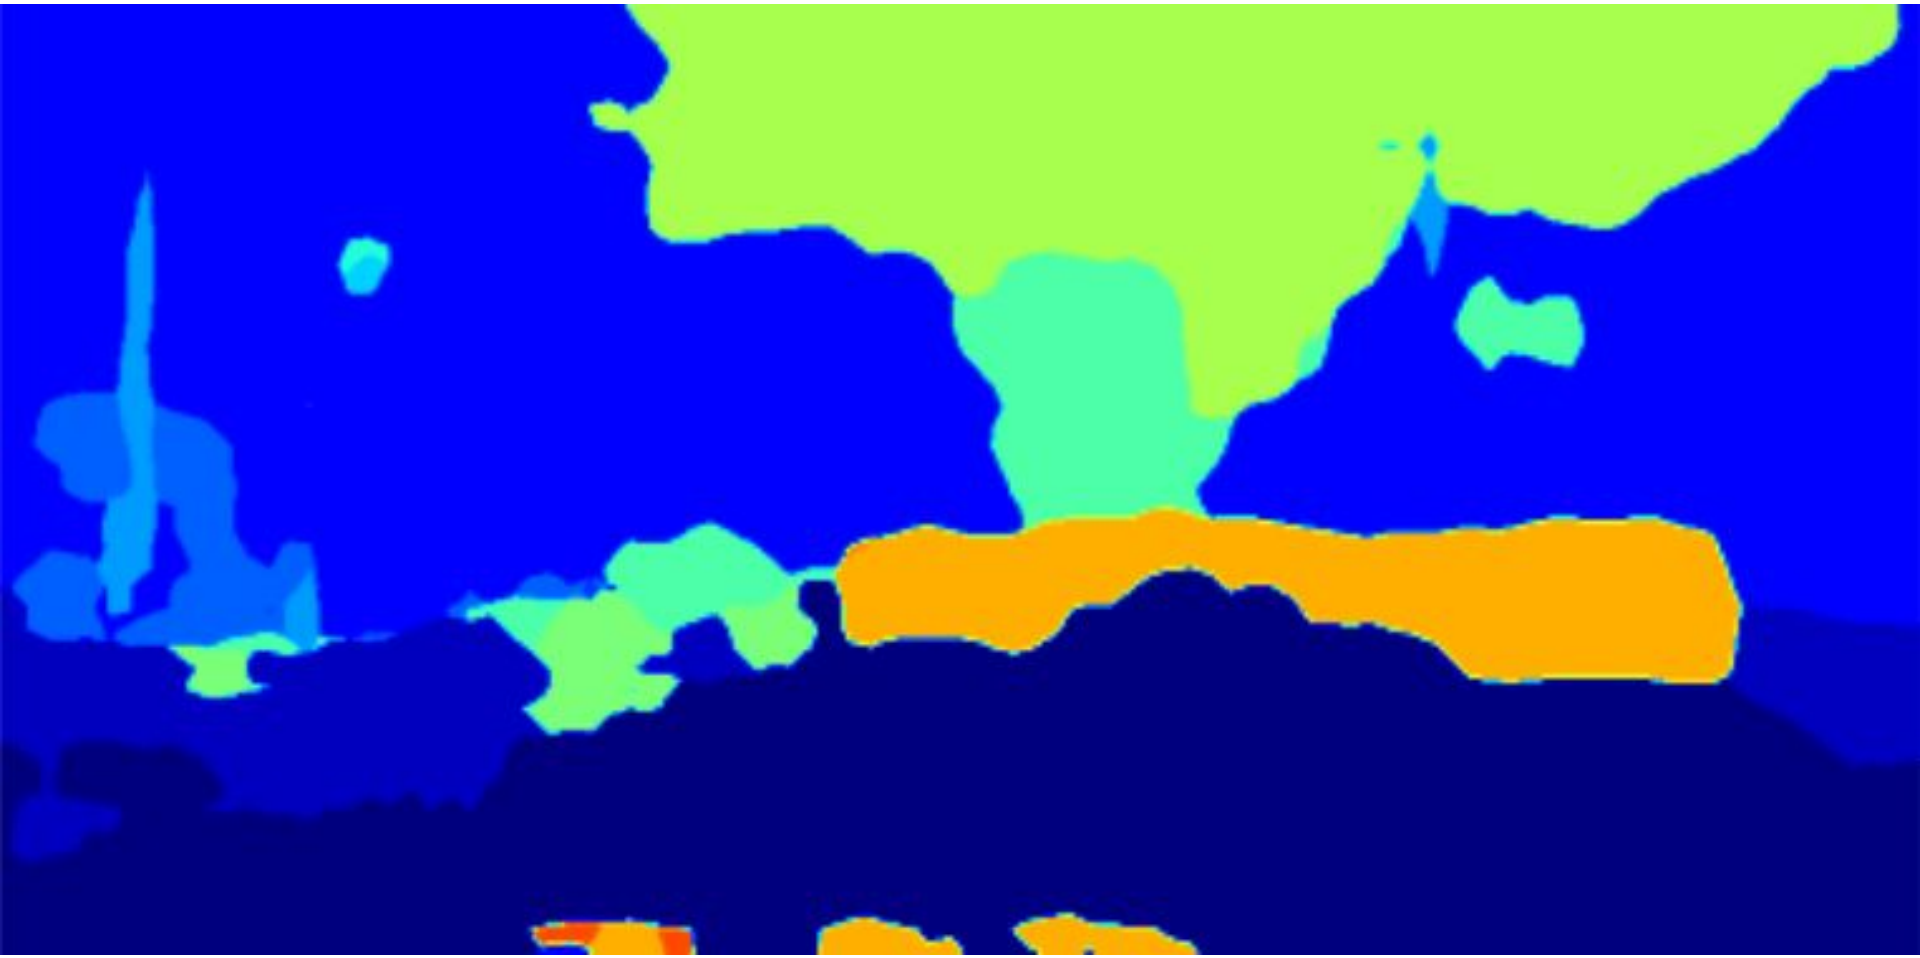
Conclusion et Benchmark

Prédiction du Modèle



Prédiction ONNX





ENSI CAEN
ÉCOLE PUBLIQUE D'INGÉNIEURS
CENTRE DE RECHERCHE

MERCI

pour votre écoute

L'École des Ingénieurs Scientifiques