ENSI CAEN
ÉCOLE PUBLIQUE D'INGÉNIEURS
CENTRE DE RECHERCHE

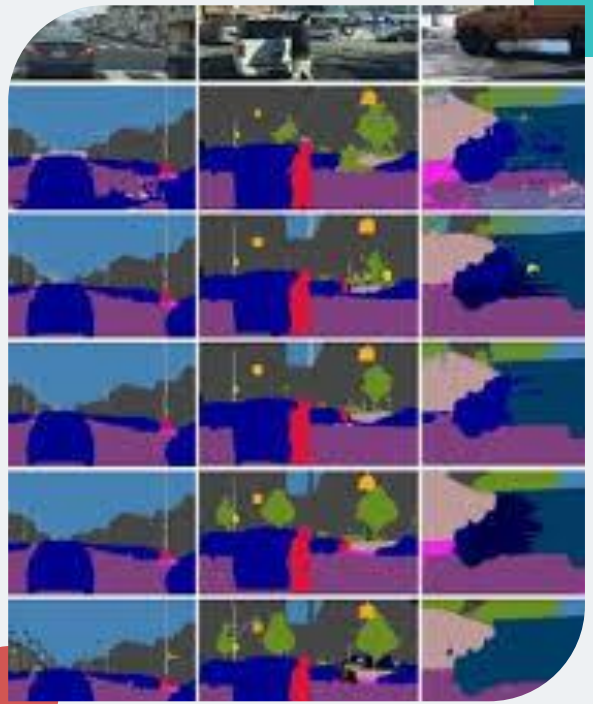
Rapport Quantisation

de Arthur DEFORGE



L'École des Ingénieurs Scientifiques

Modèle et Dataset



- Modèle : **DeepLabV3+ (Backbone ResNet50)**.
- Données : **BDD100K**
- Taille d'entrée : **768 x 384**
- ***Objectif*** : Adapter un modèle pré-entraîné sur COCO (21 classes) vers le contexte routier BDD100K (19 classes).
- ***Classes cibles*** : Road, Car, Person, Traffic Light, etc..

Stratégie : Déverrouiller le Backbone

- **Limites** de la Phase 1 (Fine-Tuning) :
  - Dans nos tests précédents, le **backbone** (ResNet50) était **figé**.
  - **Résultat** obtenu : mIoU de ~**40**.88%.
  - Problème : Le modèle extrayait des features génériques (ImageNet) mal adaptées aux spécificités de BDD100k (neige, nuit, complexité urbaine).

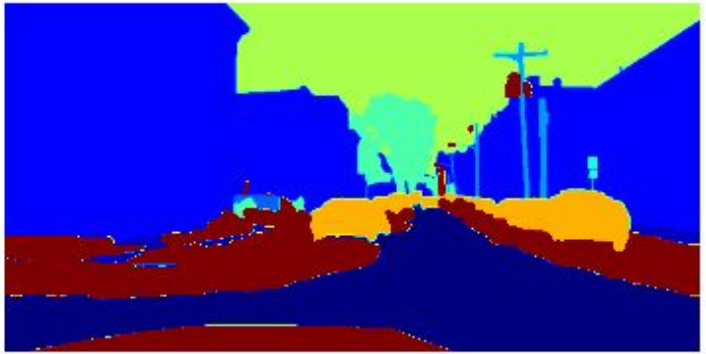
- Nouvelle Approche (**Full Retrain**) :
- Dégel complet de tous les poids du réseau (**Backbone + Classifier**).
- **Objectif** : Permettre au réseau d'apprendre des caractéristiques propres à la conduite autonome dès les premières couches.
- Coût : **Temps d'entraînement plus long**, mais gain de précision espéré significatif.

Protocole de Test : L'Image de Référence

Ref Input: 7d06fefd-f7be05a6.jpg



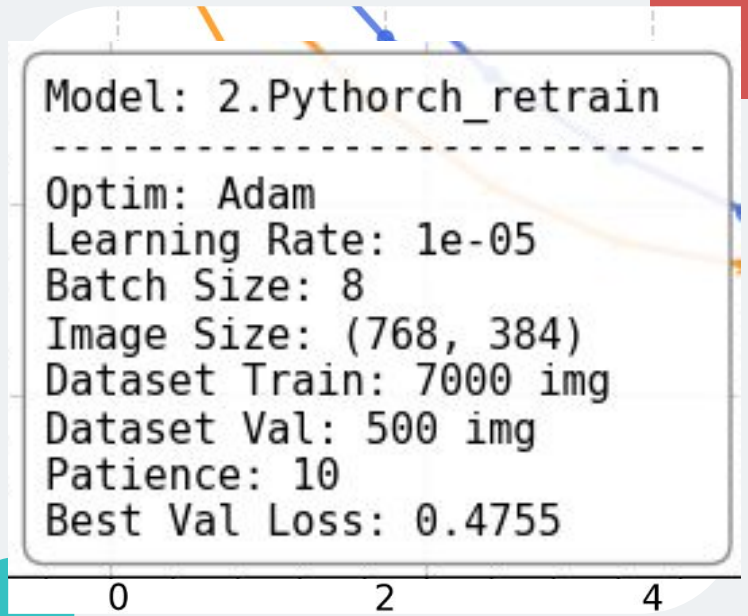
Ref Ground Truth



Cette image servira de fil conducteur tout au long du workflow.

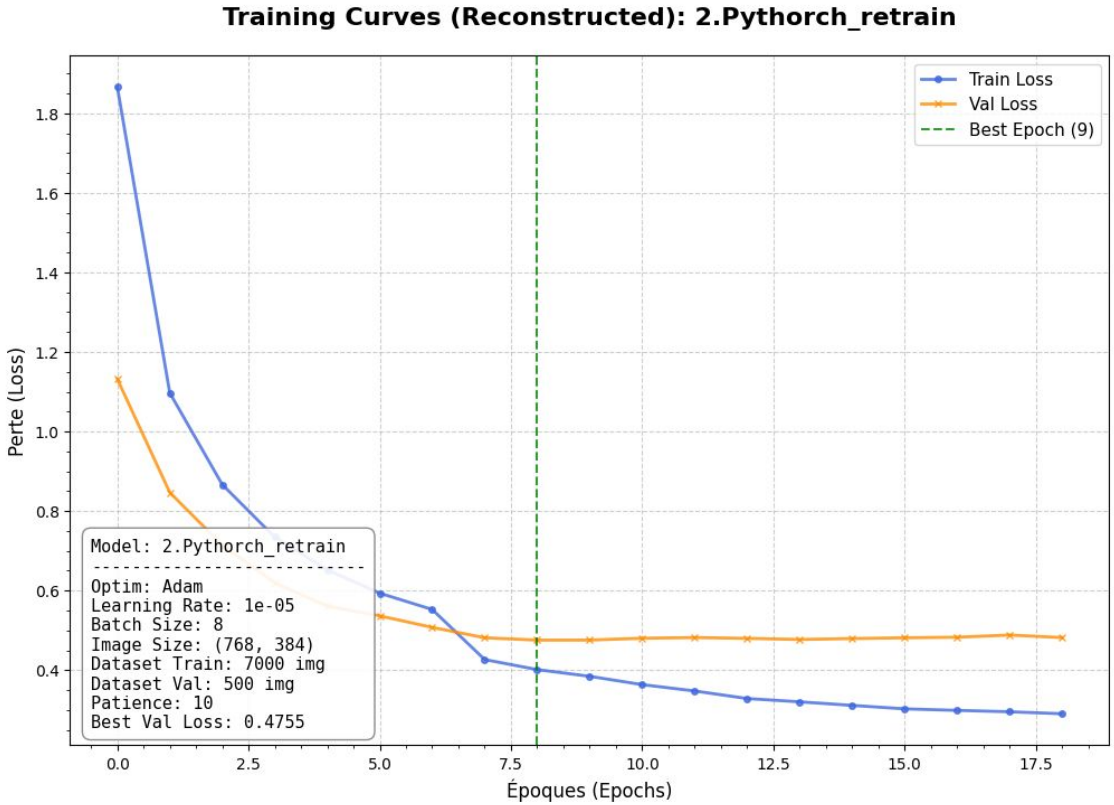
Pourquoi elle ? Scène complexe contenant : Route, Véhicules, Ciel, Végétation et panneaux. Elle permet de juger la finesse de la segmentation.

Configuration du Fine-Tuning



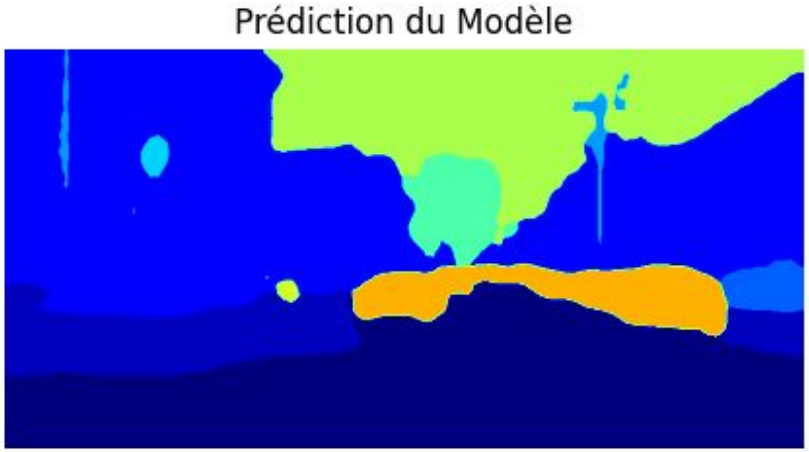
- **Architecture** : Le backbone (ResNet50) est désormais dégelé (unfrozen). Contrairement à la phase précédente, tous les poids du réseau sont mis à jour.
- **Stratégie** : Passage d'une extraction de caractéristiques génériques (ImageNet) à un apprentissage spécifique aux scènes routières complexes de BDD100k (nuit, météo, occlusion).
- **Hyperparamètres** : Maintien de l'optimiseur Adam et de la taille d'image, mais calcul du gradient étendu à l'intégralité des couches du modèle (Encodeur + Décodeur).

Performance de l'Apprentissage (PyTorch)



- Convergence rapide grâce au Transfer Learning.
- Stabilité atteinte après X époques.
- Pas de signe majeur d'overfitting.

Validation du Modèle PyTorch



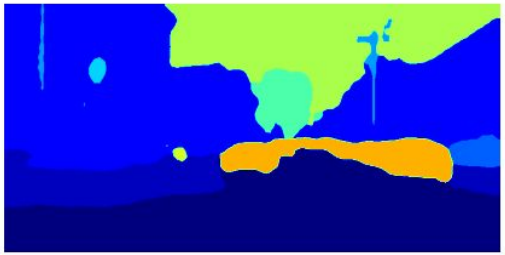
ID	Classe	Score IoU (%)	Performance
0	Road	93.43%	Excellent
1	Sidewalk	56.68%	Bon
2	Building	82.33%	Très bon
3	Wall	46.79%	Moyen
4	Fence	28.58%	Faible
5	Pole	37.24%	Faible
6	Traffic Light	37.08%	Faible
7	Traffic Sign	40.33%	Moyen
8	Vegetation	83.02%	Très bon
9	Terrain	42.35%	Moyen
10	Sky	93.03%	Excellent
11	Person	59.12%	Bon
12	Rider	0.00%	Non détecté
13	Car	86.78%	Excellent
14	Truck	68.94%	Bon
15	Bus	79.09%	Très bon
16	Train	0.00%	Non détecté
17	Motorcycle	0.00%	Non détecté
18	Bicycle	0.00%	Non détecté

Protocole de Test : Validation du Modèle PyTorch

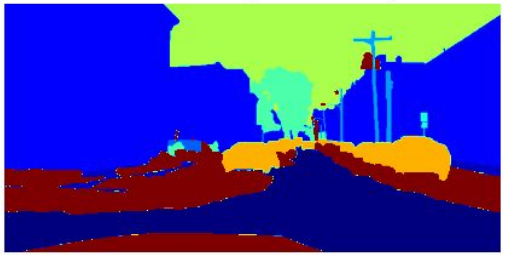
Image : 7d06fefd-f7be05a6.jpg



Prédiction du Modèle



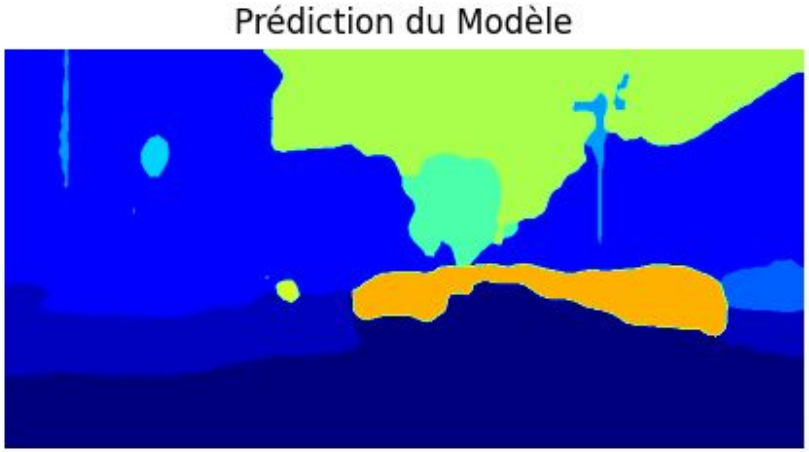
Vérité Terrain (Ground Truth)





Métrique	Valeur
Modèle	deeplabv3_resnet50_bdd100k_retrain_HR_FULL.pth
Global Pixel Accuracy	91.39%
Mean IoU (mIoU)	49.20%

Vérification de la Conversion



- **Résultat visuel :** Strictement identique au modèle PyTorch.
- **Précision :** Les scores mIoU sont inchangés (perte négligeable liée à la précision flottante).
- Le modèle est prêt pour la quantification.

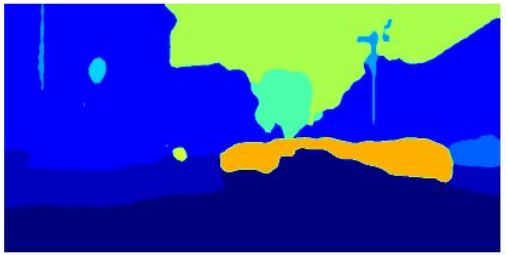
ID	Classe	Score IoU (%)	Performance
0	Road	93.43%	Excellent
1	Sidewalk	56.68%	Bon
2	Building	82.33%	Très bon
3	Wall	46.79%	Moyen
4	Fence	28.58%	Faible
5	Pole	37.24%	Faible
6	Traffic Light	37.08%	Faible
7	Traffic Sign	40.33%	Moyen
8	Vegetation	83.02%	Très bon
9	Terrain	42.35%	Moyen
10	Sky	93.03%	Excellent
11	Person	59.12%	Bon
12	Rider	0.00%	Non détecté
13	Car	86.78%	Excellent
14	Truck	68.94%	Bon
15	Bus	79.09%	Très bon
16	Train	0.00%	Non détecté
17	Motorcycle	0.00%	Non détecté
18	Bicycle	0.00%	Non détecté

Protocole de Test : Vérification de la Conversion

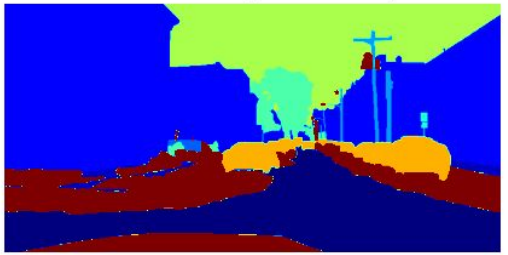
Image : 7d06fefd-f7be05a6.jpg



Prédiction du Modèle



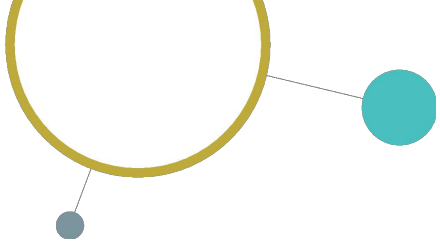
Vérité Terrain (Ground Truth)





Métrique	Valeur
Modèle	deeplabv3_resnet50_bdd100k_retrain_HR_FULL.pth
Global Pixel Accuracy	91.39%
Mean IoU (mIoU)	49.20%

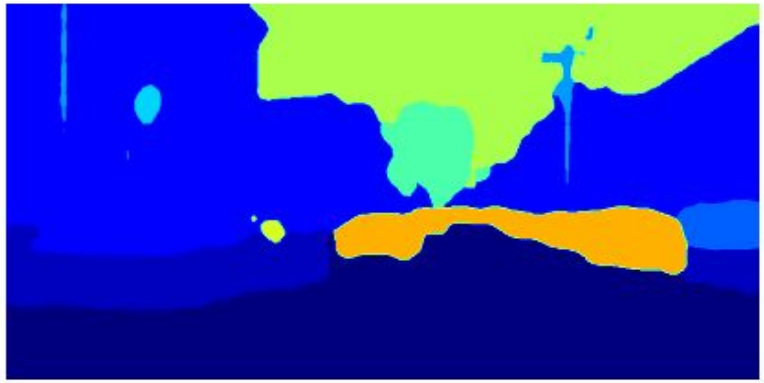
Quantification Statique (INT8)



- **Méthode :** Post-Training Quantization (Static).
- **Calibration :** Utilisation de 100 images du dataset Train pour calibrer les min/max des tenseurs.
- **Gain :** Réduction de **4x** la taille du modèle.

Impact de la Quantification

Prédiction ONNX



- **Analyse :** La perte de précision est minime (< 1%).
- Visuellement, la segmentation reste robuste sur l'image de référence.

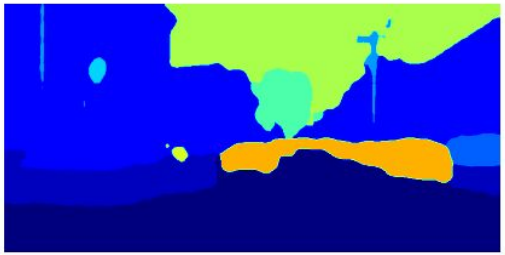
ID	Classe	Score IoU (%)	Variation vs FP32
0	Road	93.28%	Excellent
1	Sidewalk	55.85%	Bon
2	Building	81.10%	Très bon
3	Wall	43.72%	Moyen
4	Fence	26.69%	Faible
5	Pole	36.87%	Faible
6	Traffic Light	37.61%	Faible
7	Traffic Sign	40.17%	Moyen
8	Vegetation	81.72%	Très bon
9	Terrain	43.10%	Moyen
10	Sky	92.92%	Excellent
11	Person	59.52%	Bon
12	Rider	0.00%	Non détecté
13	Car	86.53%	Excellent
14	Truck	68.04%	Bon
15	Bus	79.06%	Très bon
16	Train	0.00%	Non détecté
17	Motorcycle	0.00%	Non détecté
18	Bicycle	0.00%	Non détecté

Protocole de Test : Impact de la Quantification

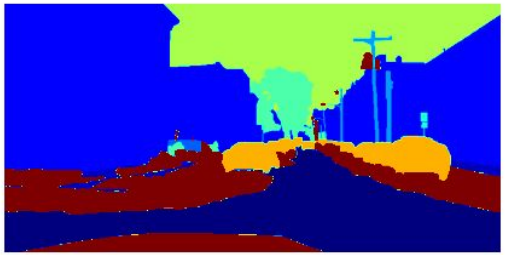
Image : 7d06fefd-f7be05a6.jpg



Prédiction ONNX



Vérité Terrain





Métrique	Valeur
Modèle	deeplabv3_resnet50_bdd100k_retrain_HR_quantized.onnx
Global Pixel Accuracy	**90.98%**
Mean IoU (mIoU)	**48.75%**

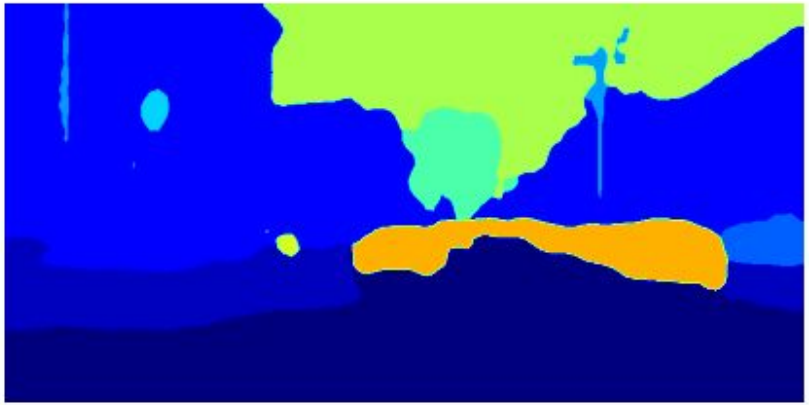
Conclusion et Benchmark

Étape	Format	Taille (MB)	Précision (mIoU)
1. Entraînement	PyTorch (.pth)	~151.15 MB	~49.20 %
2. Export	ONNX (FP32)	~151.15 MB	~49.20 %
3. Optimisation	ONNX (INT8)	~38.00 MB	~48.75 %

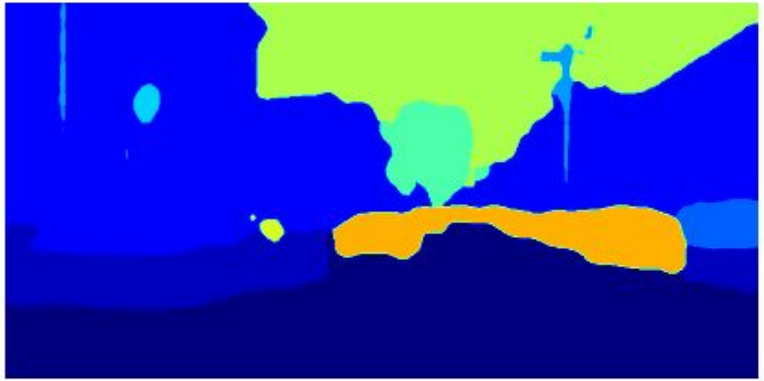
- Le workflow est validé de bout en bout.
- Le modèle est divisé par 4 en taille avec une perte de qualité négligeable.

Conclusion et Benchmark

Prédiction du Modèle



Prédiction ONNX





ENSI CAEN
ÉCOLE PUBLIQUE D'INGÉNIEURS
CENTRE DE RECHERCHE

MERCI

pour votre écoute

L'École des Ingénieurs Scientifiques